



Universidad
de Valparaíso
CHILE

Manual de Usuario

Transformador XML-JATS

Universidad de Valparaíso

Facultad de Medicina

Autor: Cristian Carreño León

Fecha: 11-12-2025

Versión: 0.5 (Beta)

Contacto: carreonleong@gmail.com

Documentación General (README)

Transformador XML JATS (JATS XML Transformer) - v0.5 (Beta)

Una herramienta avanzada impulsada por Inteligencia Artificial para convertir documentos de Word (.docx) a formato JATS XML validado, diseñada específicamente para el flujo editorial de revistas científicas.

Esta aplicación automatiza el proceso de etiquetado semántico, extracción de tablas e imágenes (en desarrollo), y validación contra el estándar NLM/NCBI Journal Publishing DTD v1.3.

Características Principales

- Conversión Inteligente: Utiliza LLMs (Google Gemini) para interpretar la estructura lógica del documento.
- Asistente de Corrección Interactivo: Chatbot integrado que ayuda a solucionar errores de validación DTD, permitiendo ediciones precisas y regeneración del XML.
- Navegación Fluida: Interfaz intuitiva con pestañas y botones de navegación automática entre pasos.
- HTML Autocontenido: Genera archivos HTML con el logo incrustado (Base64), listos para publicar sin dependencias externas.
- Validación Integrada: Valida contra JATS 1.3 y ofrece sugerencias de corrección en tiempo real.
- Conversión Inteligente: Utiliza LLMs (Google Gemini) para interpretar la estructura lógica del documento y generar etiquetas JATS precisas.
- Extracción de Contenido: Detecta y extrae imágenes y tablas automáticamente desde el archivo Word.
- Validación Integrada: Valida el XML generado contra el DTD oficial JATS 1.3 con MathML3.
- Interfaz Dual:
 - CLI (Línea de Comandos): Para automatización y procesamiento por lotes.
 - Web UI (Streamlit): Interfaz gráfica amigable para arrastrar y soltar archivos, editar contenido extraído y previsualizar resultados.
- Conversión a HTML: Genera una vista previa en HTML del artículo para su revisión inmediata.

Requisitos del Sistema

- Windows, macOS o Linux.
- [Python 3.9+](<https://www.python.org/downloads/>)
- Una clave de API de Google Gemini (Google AI Studio).

Instalación

1. Clonar el repositorio (si aplica) o descargar el código fuente.
2. Crear un entorno virtual (recomendado):

```
python -m venv .venv
```

Activar:

Windows: .venv\Scripts\activate

macOS/Linux: source .venv/bin/activate

3. Instalar dependencias:

```
pip install -r requirements.txt
```

Nota: Si no tienes un requirements.txt, las dependencias principales son: python-docx, lxml, streamlit, google-generativeai (o la herramienta CLI correspondiente).

4. Configurar la API Key de Gemini:

Asegúrate de que la CLI de gemini esté configurada en tu PATH o system environment variables.

```
export GEMINI_API_KEY="tu_clave_aqui"
```

Uso

Interfaz Web (Recomendado)

La interfaz gráfica es la forma más fácil de usar la herramienta.

1. Ejecuta la aplicación:

```
streamlit run streamlit_app.py
```

2. Abre tu navegador en la URL mostrada (usualmente <http://localhost:8501>).
3. Sube tu archivo .docx.

4. Revisa el texto extraído, genera el XML, valida y descarga los resultados.

Línea de Comandos (CLI)

Para usuarios avanzados que deseen integrar la herramienta en scripts.

Transformación (Word -> XML):

```
python -m modules.transformer entrada.docx salida.xml
```

Conversión (XML -> HTML):

```
python -m modules.xml_html entrada.xml salida.html
```

Estructura del Proyecto

- streamlit_app.py: Punto de entrada de la aplicación web (Streamlit UI).
- modules/:
 - transformer.py: Núcleo de la lógica de conversión. Maneja la lectura del Word, construcción del prompt para IA y validación XML.
 - correction.py: Módulo para la corrección asistida por IA.
 - xml_html.py: Utilidad para convertir el XML JATS resultante a HTML visualizable.
- views/: Vistas de la interfaz gráfica.
- JATS-Publishing-1-3-MathML3-DTD/: Archivos DTD locales para validación offline (se descargan si no existen).
- imagenes_extraidas/: Directorio temporal donde se guardan las imágenes extraídas del documento Word.

Créditos

Desarrollado por Cristian Carreño León\
Escuela de Obstetricia y Puericultura\
Facultad de Medicina\
Universidad de Valparaíso, Chile.

Desarrollado para la Universidad de Valparaíso con el objetivo de optimizar los procesos de publicación científica.

Historial de Versiones (Changelog)

v0.5 (Beta) - Versión Actual

- Mejoras de UI: Navegación por pestañas con botones de avance automático.
- Corrección Interactiva: Nuevo chatbot que permite dialogar con la IA para resolver errores de validación. Implementación de una "Caja de Sugerencias" para revisar y aplicar cambios al XML de forma segura.
- Logo Embedded: El logo de la revista ahora se incrusta como Base64 en el HTML generado, eliminando la dependencia de carpetas locales.
- Optimización: Eliminación de animaciones intrusivas y mejora en la legibilidad del chat en modo oscuro.

v0.1 - v0.4 (Alpha)

- Inicio del proyecto.
- Configuración de Gemini CLI.
- Extracción básica de DOCX.
- Primera implementación de transformación a XML JATS.

Guía de Contribución

Contribuir al Proyecto

¡Gracias por tu interés en mejorar el Transformador XML JATS! Este documento describe las normas y mejores prácticas para contribuir al código.

Configuración del Entorno de Desarrollo

1. Clonar el repositorio:

```
git clone <URL_DEL_REPOSITORIO>
cd <NOMBRE_DEL_DIR>
```

2. Crear un entorno virtual (Python 3.9+ recomendado):

```
python -m venv .venv
source .venv/bin/activate # En Windows: .venv\Scripts\activate
```

3. Instalar dependencias:

```
pip install -r requirements.txt
```

4. Configurar Variables de Entorno:

Asegúrate de tener acceso a la CLI de Gemini o configurar la variable `GEMINI_API_KEY` si el código lo requiere directamente.

Estilo de Código y Normas

Para mantener la calidad y legibilidad del código, exigimos el cumplimiento de las siguientes normas en todos los Pull Requests:

1. Convenciones Generales

- Seguimos PEP 8.
- Longitud de línea máxima sugerida: 100 caracteres.
- Usa `snake_case` para funciones y variables, y `PascalCase` para clases.

2. Type Hints (Tipado Estático)

Todas las funciones y métodos deben tener anotaciones de tipo (Type Hints) completas para argumentos y valores de retorno.

Correcto:

```
def procesar_texto(entrada: str, opciones: Dict[str, bool]) -> List[str]:  
    ...
```

Incorrecto:

```
def procesar_texto(entrada, opciones):  
    ...
```

3. Docstrings (Estilo Google)

Todas las funciones, clases y módulos públicos deben tener docstrings siguiendo el Google Python Style Guide.

Ejemplo:

```
def funcion_ejemplo(arg1: int, arg2: str) -> bool:  
    """Realiza una operación de ejemplo.
```

Explica brevemente qué hace la función. Puede tener múltiples líneas si es complejo.

Args:

arg1 (int): El primer argumento, que representa X.

arg2 (str): El segundo argumento, que representa Y.

Returns:

bool: True si la operación fue exitosa, False en caso contrario.

Raises:

ValueError: Si arg1 es negativo.

```
    """  
  
    ...
```

Flujo de Trabajo

1. Reportar Problemas: Abre un Issue antes de comenzar trabajos grandes.
2. Ramas (Branches): Crea ramas descriptivas, ej. feature/validacion-xml o fix/error-parseo.
3. Pull Requests:
 - Describe claramente tus cambios.
 - Asegúrate de que el código pase las validaciones locales.
 - Adjunta capturas de pantalla si cambiaste la interfaz gráfica.

Contacto

Para dudas técnicas, contacta a: cristian.carreno@uv.cl
Universidad de Valparaíso.

Manual de Usuario

El Transformador XML JATS es una herramienta especializada diseñada para optimizar y automatizar el flujo de trabajo editorial de la Universidad de Valparaíso.

Esta solución permite la conversión de manuscritos originales en formato Microsoft Word (.docx) al estándar JATS XML (Journal Archiving and Interchange Tag Suite), asegurando el cumplimiento con los requisitos de indexación y preservación digital de alto nivel.

Flujo de Trabajo

1. Carga de Archivos

- Navegue a la sección "Transformador" en el menú lateral.
- Encontrará un área designada para la carga de archivos.
- Puede arrastrar y soltar su archivo .docx o hacer clic en "Browse files" para seleccionarlo de su equipo.

Una vez cargado el archivo, el sistema realizará una extracción automática del texto:

- Revise que el texto extraído sea correcto.
- Si no es correcto, puede editar el texto manualmente.
- Agregue en esta sección información que puede estar ausente en el documento original (DOI, Fecha de publicación, etc).
- Revise que la información sea correcta.




Figura 1: Área de carga de documentos.

2. Generación de XML JATS

Una vez cargado el archivo, en la pestaña "Generación":

- Presione el botón "Generar XML JATS".
- El sistema procesará el contenido aplicando las reglas del estándar JATS 1.3.




Figura 2: Generación de XML JATS.

3. Validación y Corrección

- Presione el botón "Ejecutar Validación DTD".
- El sistema procesará el contenido aplicando las reglas del estándar JATS 1.3.
- Se ejecutará una validación automática estricta contra el DTD oficial.

Importante

- Si el sistema encuentra errores, se mostrará un informe con los errores encontrados y se habilitarán un botón de corrección que permitirá corregir los errores encontrados asistido por la IA de Gemini.
- Si el sistema no encuentra errores, se mostrará un mensaje de éxito y se habilitarán el botón de Resultados.




Figura 3: Validación de DTD.

4. Resultados

Si la validación es exitosa, se habilitarán los botones de descarga:

- Descargar XML: Archivo listo para publicación/preservación.
- Descargar HTML: Vista previa para lectura web.




Figura 4: Resultados.

Preguntas Frecuentes

¿Qué formatos soporta?

Actualmente soporta archivos Microsoft Word (.docx). Asegúrese de que el documento no esté protegido con contraseña.

¿Qué hago si falla la validación?

Revise el mensaje de error. Generalmente se debe a caracteres especiales no soportados o estructuras de documento inusuales (ej. tablas anidadas complejas). Edite el contenido en el paso 2 y reintente.

¿Es seguro subir mis archivos?

Sí, los archivos se procesan temporalmente en la memoria para su transformación y no se guardan en el servidor de forma permanente.

Créditos y Licencias

Esta herramienta ha sido desarrollada para optimizar el flujo de trabajo editorial de la Revistas UV, automatizando la conversión de manuscritos a XML JATS validado.

Desarrollador Principal:

Cristian Carreño León (cristian.carreno@uv.cl)

Tecnología:

- Python 3.9+: Lenguaje base.
- Streamlit: Framework de interfaz de usuario.
- Google Gemini Pro: Modelo de lenguaje (LLM).
- LXML: Procesamiento y validación robusta de XML.
- JATS 1.3: Estándar de etiquetado.

Privacidad y Tratamiento de Datos:

1. Procesamiento Volátil: Los archivos no se almacenan permanentemente.
2. API de Inteligencia Artificial: Se utiliza Google Gemini bajo sus términos de servicio.